



FACULTAD
DE CIENCIAS
ECONÓMICAS

FAMAF
Facultad de Matemática, Estadística,
Física y Computación



UNC

Universidad
Nacional
de Córdoba

DIPLOMATURA
CIENCIA DE DATOS, INTELIGENCIA
ARTIFICIAL Y SUS APLICACIONES
EN ECONOMÍA Y NEGOCIOS

GRUPO XI

Etchevest Jorgelina

Abellán Gastón

Zapata Fabián



INTRODUCCIÓN

La base de datos elegida contiene información de pedidos realizados entre los años 2016 y 2018 en el marketplace brasileño Olist. El dataset incluye 8 archivos CSV con información sobre los pedidos, lo que inicialmente ha requerido la unión de los diferentes dataset, con la finalidad de obtener una única base de datos.

Al realizar un primer análisis descriptivo de los datos con los que cuentan estas bases de datos, pudimos observar que la tasa de retorno del cliente es muy baja (3,05%). Dato fundamental para, posteriormente, poder determinar un modelo de machine learning que logre predecir sobre qué clientes se deben aplicar esfuerzos extra para que vuelvan a comprar en Olist.

El presente informe consta de 4 partes, la primera de ellas dedicada a la limpieza, curación de datos y análisis exploratorio de los datos. La segunda, con la reseña sobre las regresiones, tanto univariada como multivariada. A continuación se exponen los resultados de la aplicación de los modelos de machine learning, para concluir con una breve propuesta de mejora para Olist.

OBJETIVO GENERAL

- Aumentar la rentabilidad del negocio.

OBJETIVOS ESPECÍFICOS

- Incrementar la tasa de retorno.
- Fidelizar a la clientela.

PLAN DE ACCIÓN

Se intentará buscar el mejor modelo de clasificación que permita distinguir los clientes entre los que “VUELVEN” y los que “NO VUELVEN”.

Clase positiva: Los consumidores que NO vuelven.

Clase negativa: Los consumidores que vuelven.

En base a esto, nuestra métrica objetivo será la PRECISIÓN, ya que buscamos minimizar la cantidad de falsos positivos.

Un FALSO POSITIVO es un cliente que el modelo predijo como “NO VUELVE”, cuando en la realidad pertenece a la categoría “VUELVE”. Este caso implicaría, si se toman acciones de marketing para la retención de la clientela, un desembolso económico ineficiente, dado que no haría falta persuadirlo para que vuelva a realizar la compra.

Los FALSOS NEGATIVOS, si bien serían un problema, no generarían gasto para Olist. Es decir, serían clientes clasificados por el modelo como que “VUELVE” (no se haría gasto alguno en promociones, publicidad y marketing) y en realidad es un cliente que “NO VUELVE”.

LIMPIEZA, CURACIÓN Y ANÁLISIS EXPLORATORIO

SELECCIÓN DE VARIABLES

Principalmente por cuestiones operativas, dejamos de lado las variables de georeferenciación, teniendo como resultado una base de datos unificada con 39 variables. En principio realizamos pequeñas modificaciones para facilitar la funcionalidad de la base: ajustar dtype, ajustamos al inglés el idioma en categorías de productos, cambiar abreviaciones a más conocidas (Estados de Brasil) e incluso crear nuevas variables.

Procedimos a aplicar la herramienta Pandas Profiling. Por la cantidad de valores perdidos decidimos eliminar ciertas variables (6); estas estaban relacionadas con las reseñas, columna con un 88% de valores NAN.

Asimismo, buscamos reducir la cantidad de variables a través de agrupar el alto, largo y ancho de los productos en la variable volumen.

RELLENO DE MISSINGS

Para las variables numéricas continuas se utilizó como criterio de relleno de valores faltantes la mediana. En cambio, para las variables categóricas como los medios de pago decidimos utilizar la moda. Además de completar los datos faltantes, se eliminaron las filas duplicadas.

OUTLIERS

Para eliminar los outliers, los límites que se tomaron fueron 3 veces el rango intercuartílico, es decir los valores que eran más altos o más bajos que esos límites fueron removidos de la base de datos. La elección de 3 RI deviene de la cantidad de datos implicados a eliminación.

REGRESIONES: UNIVARIADA Y MULTIVARIADA

REGRESIÓN LINEAL SIMPLE

Posterior a la limpieza y el reordenamiento de la base de datos inicial, comenzamos a aplicar modelos de regresión con el objetivo de ver cómo se comportan nuestros datos.

En una primera instancia aplicamos un modelo de regresión lineal, definiendo como variable de respuesta al valor del flete y como variable explicativa al volumen. Utilizamos el método mínimos cuadrados ordinarios de la biblioteca de statsmodels(OLS). -Como complicación encontramos valores de flete =0, los cuáles fueron debidamente eliminados de la base. -

Las conclusiones de este primer modelo fueron que el volumen es una variable que aporta valor a la explicación del valor del flete, sin embargo, no explica un porcentaje de variabilidad muy considerable (34%). Por otro lado, el modelo no logró sobrepasar pruebas de hipótesis sobre sus supuestos iniciales: homocedasticidad, independencia y normalidad de los errores.

REGRESIÓN MULTIVARIADA

Al modelo inicial le añadimos dos variables explicativas: precio del producto y peso en gramos. Lamentablemente los resultados no fueron alentadores, conseguimos explicar un 44% de la variabilidad del valor del flete pero el modelo no superó las pruebas de hipótesis de los supuestos anteriormente nombrados. Otro problema que empezamos a encontrar es la multicolinealidad, volumen y peso están muy relacionadas.

Otra reversión que aplicamos al modelo multivariado incluyó los Estados a los cuáles pertenecen los clientes, lo que implicó añadir variables dummies al modelo. Como resultado logramos aumentar un poco la explicación del modelo pero no logramos superar los supuestos. Esto nos brindó un primer indicio de que la distancia podía tener un gran peso a la hora de calcular el flete.

COMPONENTES PRINCIPALES

Para hacernos una idea de las características de los productos, tomamos como variables el volumen, el precio y el peso del producto. A partir de métodos de estandarización y de eliminación de atípicos pudimos definir dos componentes principales, explicando un 90% de la variabilidad del modelo. El primer componente se ve relacionado estrechamente con productos de mayor volumen y peso, mientras que el segundo valora productos más pequeños pero de mayor valor.

CLUSTERING

Con el objetivo de analizar los principales perfiles de los clientes de Olist, aplicamos técnicas de aglomeración. Para esto realizamos una base de datos con el monto de pago, la cantidad de veces que compró (frecuencia) y la cantidad de días desde su última compra (antigüedad). Luego estandarizamos los datos y eliminamos los atípicos con la Distancia de Mahalanobis.

Posterior a la definición de la base, aplicamos una clasificación jerárquica, a partir de un dendograma; en este caso solo tomamos una muestra ya que la base entera necesitaba demasiada RAM. Nos aseguramos de que sea representativa y como conclusión definimos tres clusters. Posteriormente, aplicamos un método no jerárquico (K-Means) y obtuvimos resultados similares.

En resumen, encontramos tres clusters, dos con nivel de gasto bajo y frecuencia baja (pero con gran diferencia en antigüedad). El tercer cluster muestra clientes con mayor frecuencia de compra, y mayor nivel de gasto pero con una antigüedad promedio.

MODELOS DE MACHINE LEARNING

PREPARACIÓN DATOS

Comenzamos el proceso de generación de nuevas variables y transformación de las existentes para la aplicación de los diferentes modelos de Machine Learning; en este caso implicó eliminar la variable ID del cliente y todas aquellas que fueran categóricas, por ejemplo, en lugar de Estado, se completó con las ventas promedio de aquel Estado.

La base de datos posee un 84,9% de clientes que no regresan y un 15,1% de clientes que sí lo hacen. Por esto, se procedió a realizar un rebalanceo de clases. Iniciando con la reducción de la clase mayoritaria ("NO VUELVE"), de forma tal que quedaran el 80% de las observaciones en esa

categoría. Y la otra clasificación ("VUELVE") quedó con las observaciones originales, que ahora representan el 20% de las observaciones en la base de datos.

Una vez re-balanceadas las clases, para la separación de los datos en training (60%) y test (40%) se utilizó el método "Stratified Sampling" que mantuvo las proporciones entre clientes que "VUELVEN" Y "NO VUELVEN" en los datos de training y test.

Se procedió a posterior al re-escalamiento de datos (menos las variables dummies), es decir, se transforman los datos de forma tal que estén comprendidos entre 0 y 1.

ÁRBOLES DE DECISIÓN

- UN ÁRBOL

Comenzamos por este método al ser uno de los más sencillos e intuitivos. Como método pre-pruning se eligió como profundidad 4. Esto es necesario para evitar el overfitting, dado que de no poner una condición para frenar de antemano, el árbol llegará a un ajuste perfecto para la muestra de entrenamiento.

Resultados obtenidos:

Los árboles de decisión permiten estimar y graficar la relevancia de cada una de las variables elegidas para explicar la variable frecuencia de compra. Las variables que no poseen relevancia serían algunas de las formas de pago (boleto, tarjeta de débito, voucher) y el volumen. Mientras que, las variables con mayor relevancia a la hora de la clasificación serían el valor del flete y el precio promedio.

ACCURACY en TRAINING SET	0.855018
ACCURACY en TEST SET	0.849468
PRECISION	0.94
RECALL	0.86


- RANDOM FOREST

Este método combina más de un árbol, donde cada árbol es diferente de los demás. En este caso hemos elegido 5 árboles. La idea es que cada árbol sobreajusta parte de los datos, pero si utilizamos varios árboles que sobreajustan en diferentes formas, se puede reducir ese efecto promediando sus resultados.

Resultados obtenidos:

Al utilizar 5 árboles mejoró el resultado de Accuracy tanto en la parte de entrenamiento como en test. Además todas las variables, ahora tienen relevancia. La importancia dada por el "bosque" es más confiable que la provista por un único árbol. No obstante ello, el valor del flete sigue siendo el feature más relevante para la clasificación entre clientes que volvieron a realizar una compra de aquellos que no lo hicieron, seguido como variable relevante por el precio promedio.

ACCURACY en TRAINING SET	0.992905
ACCURACY en TEST SET	0.932200
PRECISION	0.95
RECALL	0.96



KNN

Comenzaremos entrenando el modelo más sencillo que considera el vecino más cercano (uno solo). Es decir que una observación nueva, tendrá la etiqueta y será clasificada como la observación más cercana a la que se encuentre el modelo.

Para luego llevar adelante la búsqueda del mejor número de vecinos. Dicho procedimiento lo realizamos con el método Cross Validation, que subdivide los datos y varios modelos son entrenados. Lo realizamos evaluado entre 1 y 15 vecinos. Para optimizar el tiempo de cómputo se utilizó la variante Halving Cross Validation que va descartando configuraciones menos prometedoras, entrenando solo las configuraciones más prometedoras con más datos.

El resultado obtenido fue: 8 vecinos. Una vez entrenado el modelo con ese hiperparámetro, se obtuvieron los siguientes resultados:

Resultados obtenidos:

ACCURACY en TRAINING SET	1.000000
ACCURACY en TEST SET	0.854274
PRECISION	0.87
RECALL	0.96

MODELOS LINEALES



Se aplicaron varios métodos de clasificación lineales: algoritmo del Perceptrón, SVM (Support Vector Machine) y este último para varios kernels. El modelo con mejor performance es el SVM con un kernel RBF.

Resultados obtenidos:

ACCURACY en TRAINING SET	0.940039
ACCURACY en TEST SET	0.873670
PRECISION	0.91
RECALL	0.93

CURVA ROC ENTRE RANDOM FOREST Y SVM

La comparación de modelos se lleva a cabo entre Random Forest y SVM (Kernel: RBF) dado que ambos modelos presentaron el accuracy más alto para test y un valor de precisión alto.



CURVA PRECISION-RECALL ENTRE RANDOM FOREST Y SVM

Recordando nuestro objetivo económico para Olist, necesitamos la mayor tasa de Precisión, es decir quisiéramos minimizar el número de FALSOS POSITIVOS. Aquellos consumidores, clasificados con los modelos como "NO VUELVE" (lo que implicaría un erogación de dinero por parte de OLIST) cuando en realidad iba a volver a realizar una compra.

PROCESAMIENTO DE LENGUAJE NATURAL.

Por último, aplicamos modelos de aprendizaje profundo para realizar un análisis de sentimientos a las reseñas escritas por los consumidores de Olist. Ordenamos la base de datos, quedándonos con la reseña que escribieron y el puntaje otorgado. En el caso de Olist, la puntuación del nivel de satisfacción va de 1 a 5. Se creó la variable "SENTIMIENTO" donde será "NEGATIVO" si la puntuación va de 1 a 3 y "POSITIVO" si la puntuación del consumidor está entre 4 y 5.

Aplicando un modelo de redes neuronales multicapas el modelo de clasificación de reseñas "POSITIVAS" Y "NEGATIVAS" arrojó un ACCURACY de 0.69. Adicionalmente, nos interesa en este caso el RECALL (0.98) dado que deseamos minimizar los falsos negativos, es decir aquellas reseñas clasificadas como "NEGATIVAS" y en realidad fueron "POSITIVAS".

El interés en esta clasificación tiene su fundamento en poder diferenciar las reseñas a los fines de implementar mejoras y lograr una mayor satisfacción que impactará de lleno en la tasa de retorno.

PROPUESTA DE MEJORA

Del análisis de las métricas y las curvas ROC Y P-R podemos concluir que el mejor modelo de clasificación entrenado para nuestra base de datos es el RANDOM FOREST. Además el modelo

provee la relevancia de cada feature a la hora de clasificar nuestros datos. Siendo el más relevante el valor del flete.

Propuesta:

Cuando un nuevo cliente vaya llenando sus datos en la plataforma virtual de Olist para una compra, se podrá utilizar el modelo de clasificación seleccionado para determinar si ese consumidor “VUELVE” o “NO VUELVE”. En caso de ser clasificado como “NO VUELVE” se sugieren tres opciones:

- A. Aplicar descuento para una próxima compra. Al momento de confirmar la compra, ya sea en la plataforma o en el correo de confirmación, generar un descuento en el flete del próximo envío. O en vez de aplicarlo en el flete, aplicarlo en ciertos productos. Además, el tener una fecha límite de uso puede ayudar a que el incentivo genere mayor necesidad.
- B. Ofrecer productos complementarios de manera inmediata y prolongada en un lapso corto de tiempo. Sabiendo lo que el cliente compró, se puede desarrollar un algoritmo que ofrezca productos complementarios.
- C. Comunicar con clientes después de un período de tiempo determinado. Por ejemplo, si la última compra sucedió hace un mes, comunicarse vía email y ofrecer productos o simplemente invitar a que recorra la plataforma.

También se podrían aplicar herramientas que permiten reducir los “NO VUELVE” desde antes de concretar la compra:

- A. Bonificar el envío a partir de cierto monto mínimo. Esto impulsa a elevar el ticket de compra y a aumentar la cantidad comprada.
- B. Desarrollar un programa de fidelidad, que tenga distintos niveles a partir de ciertas cantidades de compras y que permita que el cliente obtenga beneficios únicos, por ejemplo un regalo por su cumpleaños, y descuentos sobre envíos a medida que escala en nivel de cliente. Esto ofrecerá las ventajas de clientes más satisfechos y más motivados a comprar, ya que la marca reconoce su lealtad y la premia.
- C. Aplicar y evaluar opciones A/B en precios. Fomentar productos con más de una valorización, por ejemplo, precios altos que impliquen envío gratis, precios más bajos que contemplen envíos más costosos. Si bien las dos variables son las más importantes según el árbol de decisión, se pueden alternar entre estas opciones para averiguar cuál resulta más atractiva, o simplemente contemplar ambas para todos los productos. Lo mismo es aplicable para los medios de pago.

Todas estas ideas, aplicables previa o posteriormente a clasificar el cliente en “VUELVE” o “NO VUELVE”, pueden ser de gran valor para la empresa.

La idea es proveer sugerencias que puedan ayudar a Olist sin someterse a una inversión mayor como sería renegociar con nuevos proveedores de servicios de logística o contemplar la reubicación de sus centros de distribución.

Adicionalmente, sería de valor revisar las reseñas que el modelo clasifique como negativas, incluso aquellas que sean clasificadas erróneamente (según el puntaje) esconden aspectos donde se puede mejorar, por ejemplo en el empaque; es decir, Olist no debe confiarse de las puntuaciones.